

MINI PROJECT



Disusun dalam rangka memenuhi persyaratan untuk menggantikan UTS mata kuliah
Pembelajaran Mendalam untuk Teknik Elektro Program Studi S2 Teknik Elektro

Kelompok 5:

Sadam Al Rasyid (201012420026)

Wahyu Primadia Kusumaningrum (201012420016)

Raihan Fadilla Hakim ()

FAKULTAS TEKNIK ELEKTRO

UNIVERSITAS TELKOM

BANDUNG

2025

DAFTAR ISI

DAFTAR ISI.....	ii
BAB I PENDAHULUAN.....	3
1.1 Latar Belakang.....	3
1.2 Tujuan	3
BAB II METODE.....	4
2.1 MULTILAYER PERCEPTRON (MLP).....	4
2.2 CONVOLUTIONAL NEURAL NETWORK (CNN)	5
2.3 SUPPORT VECTOR MACHINE (SVM)	6
BAB III HASIL DAN ANALISIS	7
3.1 Pengujian Sistem.....	7
3.1.1 MLP	7
3.1.2 CNN.....	11
3.1.3 SVM.....	14
3.2 Hasil	17
BAB IV PENUTUP	18
4.1 Kesimpulan	18
4.2 Saran	18
BAB V LAMPIRAN.....	19

BAB I

PENDAHULUAN

1.1 Latar Belakang

Di industri telekomunikasi terdapat persaingan besar di antara penyedia layanan internet. Jika penyedia ingin meningkatkan pendapatannya, mereka membutuhkan lebih banyak pelanggan baru, namun menjaga pelanggan lama yang ada, itu lebih penting daripada mendapatkan yang baru. Jadi, provider ingin mengetahui pelanggan mana yang mungkin akan membatalkan layanannya. Kita menyebut kondisi ini sebagai churn. Jika mereka tahu siapa saja pelanggan yang akan berhenti, provider bisa memberikan promosi khusus untuk membuat pelanggan tersebut bertahan. PT. Intenet Disini, mengumpulkan data dari pelanggan yang menggunakan layanan internet dan memberi label pada data tersebut apakah pelanggan tersebut mengalami churn atau tidak. Anda dapat menggunakan dataset ini untuk membuat model churn dan memprediksi kemungkinan churn

1.2 Tujuan


1. Membuat model churn pada dataset pelanggan PT.Internet yang telah disediakan
2. Melakukan prediksi kemungkinan churn pada data pelanggan PT.Internet.

BAB II METODE

2.1 MULTILAYER PERCEPTRON (MLP)

Multilayer Perceptron (MLP) merupakan salah satu jenis dari *Artificial Neural Network* (ANN) yang paling umum dan banyak digunakan dalam berbagai permasalahan klasifikasi maupun regresi. MLP termasuk dalam kategori feedforward neural network, yang berarti aliran data bergerak maju dari input menuju output tanpa loop atau siklus.

MLP terdiri dari tiga jenis lapisan utama, yaitu *input layer*, satu atau lebih *hidden layer*, dan *output layer*. Masing-masing lapisan terdiri dari sejumlah *neuron* (*perceptron*) yang saling terhubung antar lapisan melalui bobot (*weights*) dan bias. Setiap neuron menghitung kombinasi linier dari inputnya yang kemudian diproses melalui fungsi aktivasi untuk menambahkan non-linearitas terhadap model.




Gambar 2.1 Arsitektur *Multilayer Perceptron*

Pada gambar 2.1 merupakan arsitektur MLP yang terdiri dari *input layer* yang berfungsi untuk menerima data fitur (variabel independen), *hidden layers* yang berfungsi untuk melakukan transformasi terhadap input menggunakan fungsi aktivasi seperti ReLU, sigmoid, atau tanh, dan *output layer* yang berfungsi menghasilkan prediksi akhir. Untuk klasifikasi biner biasanya menggunakan sigmoid, sementara klasifikasi multi-kelas menggunakan softmax.

2.2 CONVOLUTIONAL NEURAL NETWORK (CNN)

Convolutional Neural Network (CNN) adalah salah satu arsitektur deep learning yang secara khusus dirancang untuk mengolah data berdimensi dua seperti gambar. CNN merupakan pengembangan dari Multilayer Perceptron (MLP) yang mampu mengenali pola spasial dan hubungan antar piksel dalam citra, sehingga sangat efektif untuk tugas-tugas seperti klasifikasi gambar, pengenalan objek, analisis dokumen, dan pengolahan video. Saat ini CNN dapat digunakan untuk prediksi churn pelanggan, khususnya pada data berdimensi tinggi atau data deret waktu (*time series*) yang kompleks. CNN mampu secara otomatis mengekstraksi fitur penting dari data tanpa perlu rekayasa fitur manual, sehingga sangat efektif untuk mengidentifikasi pola-pola yang berhubungan dengan perilaku pelanggan yang akan churn (berhenti berlangganan).

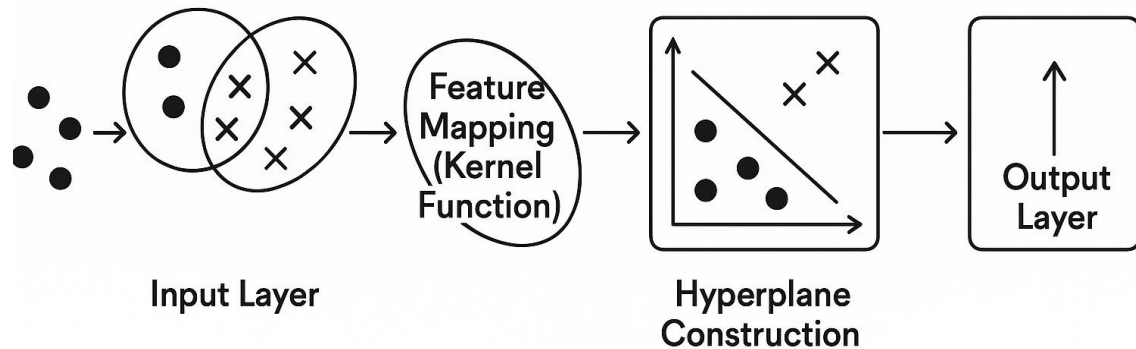


Gambar 2.2. Arsitektur CNN

Pada gambar 2.2 merupakan gambar arsitektur CNN yang digunakan dalam mini proyek ini. Pada gambar 2.2 terdapat 8 lapisan yaitu, *Input Layer* yang berfungsi untuk menerima data fitur pelanggan, misalnya data transaksi, demografi, atau interaksi layanan yang telah direpresentasikan dalam format matriks atau vektor berdimensi. Lapisan *Convolutional Layer* menerapkan filter untuk mendeteksi pola-pola penting dalam data, seperti pola perilaku pelanggan yang berpotensi churn. Lapisan *Activation Layer (ReLU)* berfungsi memperkenalkan *non-linearitas* agar model dapat belajar pola kompleks. Layer *Pooling Layer* berfungsi mengurangi dimensi data sambil mempertahankan fitur penting, mempercepat proses pelatihan dan mengurangi risiko overfitting. Lapisan *Flatten Layer* berfungsi mengubah data hasil ekstraksi fitur menjadi vektor satu dimensi untuk diteruskan ke lapisan fully connected. Pada lapisan *Fully Connected Layer* dilakukan tahapan klasifikasi berdasarkan fitur yang telah diekstrak. Pada lapisan terakhir *Output Layer* berfungsi menghasilkan probabilitas atau kelas akhir apakah pelanggan akan churn atau tidak.

2.3 SUPPORT VECTOR MACHINE (SVM)

Support Vector Machine (SVM) adalah algoritma *supervised learning* yang digunakan untuk klasifikasi maupun regresi. SVM bekerja dengan membangun sebuah *hyperplane* atau bidang pemisah optimal yang memaksimalkan margin antara dua kelas dalam ruang fitur berdimensi tinggi. Tujuannya adalah memisahkan data dari dua kelas (misal: churn dan tidak churn) dengan batas yang paling optimal, sehingga model dapat melakukan generalisasi yang baik pada data baru



Gambar 2.3 Arsitektur SVM

Pada gambar 2.3 merupakan arsitektur SVM yang digunakan dalam mini proyek ini yang terdiri dari empat lapisan, yaitu *Input Layer* yang berfungsi untuk menambahkan data pelanggan (fitur-fitur seperti lama berlangganan, jumlah transaksi, aktivitas terakhir, dll) dimasukkan sebagai vektor fitur. Lapisan kedua *Feature Mapping (Kernel Function)* berfungsi untuk filter data jika data tidak linier, fitur dipetakan ke ruang berdimensi lebih tinggi menggunakan fungsi kernel, sehingga data dapat dipisahkan secara linier. Lapisan ketiga *Hyperplane Construction* model SVM mencari hyperplane optimal yang memisahkan kelas churn dan tidak churn dengan margin maksimal. Lapisan terakhir yaitu *Output Layer* yang berfungsi sebagai *output* berupa prediksi kelas: churn atau tidak churn.

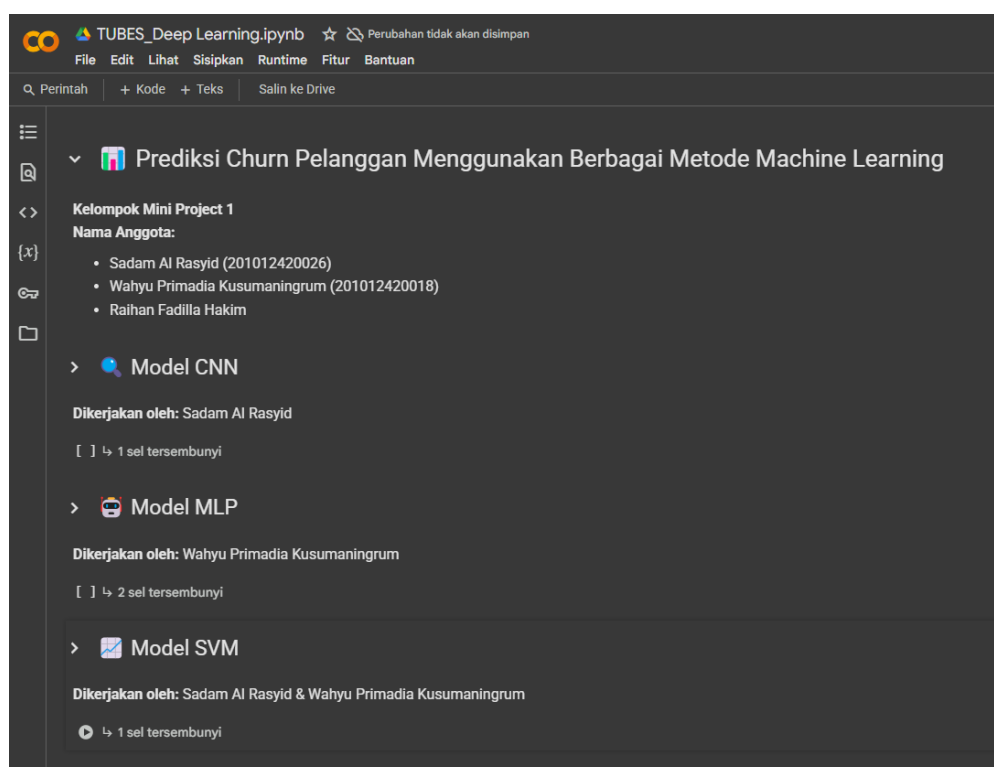
BAB III

HASIL DAN ANALISIS

3.1 Pengujian Sistem

Pengujian sistem pada bab ini akan dilakukan menggunakan dataset 1 yang berisi data pelanggan PT. Internet yang telah disediakan. Dataset yang digunakan berupa data pada csv dengan jumlah data 70% digunakan untuk proses *training* dan 30% untuk *testing*. Proses *training* merupakan pembuatan model yang selanjutnya akan diteruskan ke proses *testing* data. Pengujian sistem ini berfungsi untuk mengetahui jumlah pelanggan churn dan pengujian sistem dilakukan menggunakan Google Colab.

<https://colab.research.google.com/drive/1B7XMybXaHvoOMNqhGxg71Bp1caHk8slj?usp=sharing>




3.1.1 MLP

Dataset yang berisi data pelanggan PT. Internet akan diuji menggunakan metode MLP dengan parameter pada tabel 3.1.


Tabel 3.1. Parameter Pengujian Dengan Metode MLP

<i>Optimizer</i>	Adam
<i>Learning Rate</i>	0,001
<i>Epoch</i>	150
<i>Batch Size</i>	32




Gambar 3.1 Hasil klasifikasi pelanggan menggunakan metode MLP


Pada proses klasifikasi pertama didapatkan hasil seperti pada gambar 3.1 yang menunjukkan jumlah pelanggan tidak churn dan churn. Jumlah pelanggan churn lebih tinggi jika dibandingkan dengan jumlah pelanggan tidak churn. Pada tahapan selanjutnya dilakukan proses analisis fitur MLP dengan target nya, hasil analisis fitur dapat dilihat pada gambar 3.2. Setelah mendapatkan korelasi fitur tahapan selanjutnya adalah dengan membangun arsitektur MLP model yang telah ditingkatkan.



Gambar 3.2 Korelasi fitur dengan target



Gambar 3.3 Grafik hasil akurasi dan grafik loss



Gambar 3.4. Confussion Matrix

Gambar 3.3 merupakan grafik hasil akurasi dan grafik loss dan gambar 3.4 merupakan confusion matrix, didapatkan nilai akurasi 98,78 % dengan nilai loss 5,2%, precision 99%, recall 99%, dan f1-score 99%. Setelah mendapatkan hasil tersebut dilanjutkan dengan melakukan optimasi threshold untuk meningkatkan tingkat akurasinya.

```

Optimal threshold: 0.2505

Metrik dengan threshold optimal:
Accuracy: 0.9898
Confusion Matrix:
[[ 9616    52]
 [  169 11846]]

```

	precision	recall	f1-score	support
0	0.98	0.99	0.99	9668
1	1.00	0.99	0.99	12015
accuracy			0.99	21683
macro avg	0.99	0.99	0.99	21683
weighted avg	0.99	0.99	0.99	21683

```

Metrik Bisnis:
Total pelanggan dalam test set: 21683
Pelanggan aktual yang churn: 12015 (55.41%)
Pelanggan diprediksi churn (threshold=0.5): 11810 (54.47%)
Pelanggan diprediksi churn (threshold optimal=0.2505): 11898 (54.87%)

10 Pelanggan dengan risiko churn tertinggi:

```

	id	actual_churn	predicted_churn	churn_probability
5064	5064	1	1	1.0
6940	6940	1	1	1.0
11742	11742	1	1	1.0
4722	4722	1	1	1.0
10621	10621	1	1	1.0
18695	18695	1	1	1.0
71448	71448	1	1	1.0
6332	6332	1	1	1.0
125	125	1	1	1.0
2010	2010	1	1	1.0

Gambar 3.5 Hasil optimasi threshold

Pada gambar 3.5 dapat dilihat hasil akurasi setelah dilakukan optimasi threshold nilai akurasi menjadi 98,98% dengan total data pelanggan yang digunakan untuk test sebesar 21.683 dan didapatkan pelanggan actual yang churn sebanyak 12.015 pelanggan atau 55,41% dan pelanggan diprediksi churn (threshold=0,5) sebanyak 11.810 atau 54,47% setelah dilakukan pengoptimlan threshold dengan nilai threshold optimal 0,2505 didapatkan jumlah pelanggan diprediksi churn sebanyak 11.898 atau 54,87%. Pada gambar 3.5 juga didapatkan 10 pelanggan dengan resiko churn tertinggi. Pada gambar 3.6 dibawah merupakan hasil analisis model MLP, didapatkan akurasi model 98,78% dengan jumlah total pelanggan yang dianalisis berjumlah 72.274 dengan jumlah pelanggan yang terindikasi churn sebesar 55,41% dengan 40.050 pelanggan.

```

✓ Hasil prediksi telah disimpan ke 'hasil_prediksi_churn_mlp_enhanced.csv'
✓ Model telah disimpan ke 'telecom_churn_mlp_model_enhanced.h5'

Ringkasan Model Prediksi Churn (MLP Enhanced)
=====
Jumlah total pelanggan dalam analisis: 72274
Jumlah total pelanggan churn: 40050 (55.41%)
Akurasi model: 98.78%
AUC score: 0.9991

✓ Analisis Selesai!

```


Gambar 3.6 Hasil model prediksi churn dengan MLP

3.1.2 CNN

Dataset yang berisi data pelanggan PT. Internet akan diuji menggunakan metode CNN dengan parameter pada tabel 3.2.


Tabel 3.2 Parameter Pengujian Dengan Metode CNN

<i>Optimizer</i>	Adam
<i>Learning Rate</i>	0,001
<i>Epoch</i>	100
<i>Batch Size</i>	64




Gambar 3.7 Hasil klasifikasi pelanggan menggunakan metode CNN

Pada proses klasifikasi pertama didapatkan hasil seperti pada gambar 3.7 yang menunjukkan jumlah pelanggan tidak churn dan churn. Jumlah pelanggan churn lebih tinggi jika dibandingkan dengan jumlah pelanggan tidak churn. Pada tahapan selanjutnya dilakukan proses analisis fitur CNN dengan target nya, hasil analisis fitur dapat dilihat pada gambar 3.8. Setelah mendapatkan korelasi fitur tahapan selanjutnya adalah dengan membangun arsitektur CNN model yang telah ditingkatkan.




Gambar 3.8 Korelasi fitur dengan target

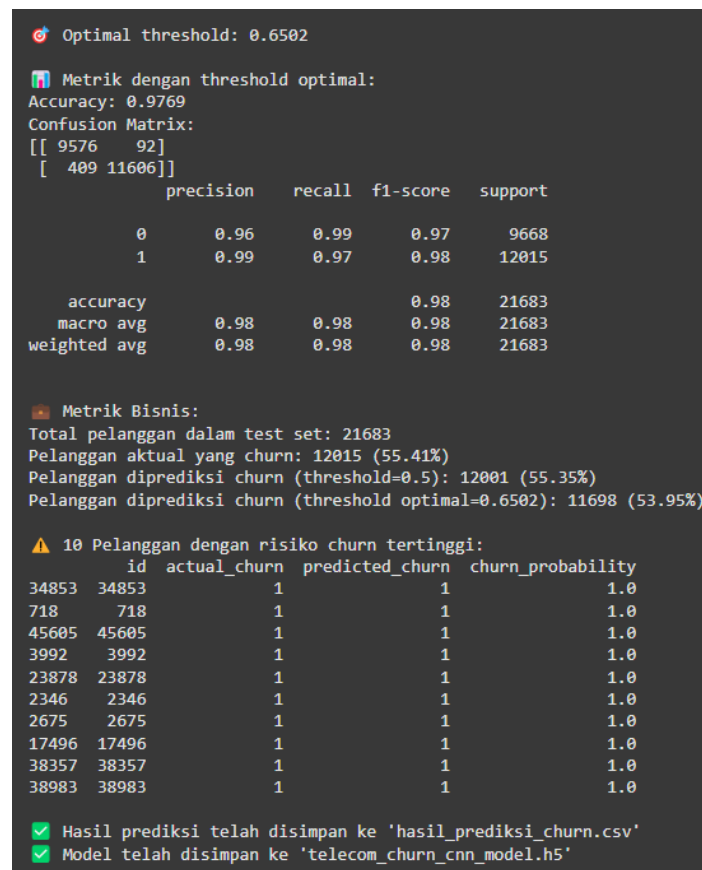


Gambar 3.9 Grafik hasil akurasi dan grafik loss

Gambar 3.9 merupakan grafik hasil akurasi dan grafik loss dan gambar 3.10 merupakan confusion matrix, didapatkan nilai akurasi 97,54 % dengan nilai loss 6,5%, precision 97,5%, recall 97,5%, dan f1-score 97,5%. Setelah mendapatkan hasil tersebut dilanjutkan dengan melakukan optimasi threshold untuk meningkatkan tingkat akurasinya.



Gambar 3.10. *Confussion Matrix*



Gambar 3.11 Hasil optimasi threshold

Pada gambar 3.11 dapat dilihat hasil akurasi setelah dilakukan optimasi threshold nilai akurasi menjadi 97,69% dengan total data pelanggan yang digunakan untuk test sebesar 21.683 dan didapatkan pelanggan aktual yang churn sebanyak 12.015 pelanggan atau 55,41% dan pelanggan diprediksi churn (treshhold=0,5) sebanyak 12.001 atau 55.35% setelah dilakukan pengoptimlan threshold dengan nilai threshold

optimal 0,6502 didapatkan jumlah pelanggan diprediksi churn sebanyak 11.698 atau 53,95%. Pada gambar 3.11 juga didapatkan 1d 10 pelanggan dengan resiko churn tertinggi. Pada gambar 3.12 dibawah merupakan hasil analisis model CNN, didapatkan akurasi model 97,54% dengan jumlah total pelanggan yang dianalisis berjumlah 72.274 dengan jumlah pelanggan yang terindikasi churn sebesar 55,41% dengan 40.050 pelanggan.

```

Ringkasan Model Prediksi Churn
=====
Jumlah total pelanggan dalam analisis: 72274
Jumlah total pelanggan churn: 40050 (55.41%)
Akurasi model: 97.54%
AUC score: 0.9975

✅ Analisis Selesai!

```

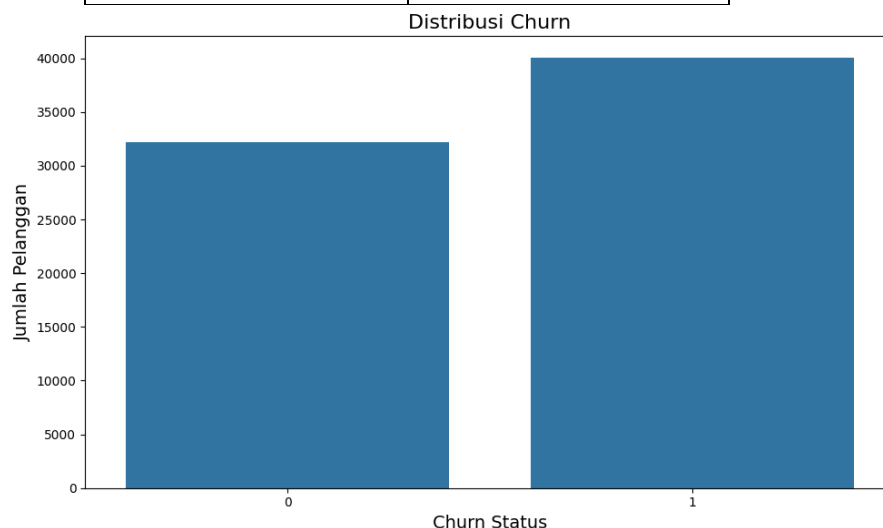
Gambar 3.12 Hasil model prediksi churn dengan CNN

3.1.3 SVM

Dataset yang berisi data pelanggan PT. Internet akan diuji menggunakan metode SVM dengan parameter pada tabel 3.3.

Tabel 3.3 Parameter Pengujian Dengan Metode SVM


Toleransi Oulier (C)	10
Gamma	0,1
Cache Size	1000




Gambar 3.13 Hasil klasifikasi pelanggan menggunakan metode SVM

Pada proses klasifikasi pertama didapatkan hasil seperti pada gambar 3.13 yang menunjukkan jumlah pelanggan tidak churn dan churn. Jumlah pelanggan churn lebih

tinggi jika dibandingkan dengan jumlah pelanggan tidak churn. Pada tahapan selanjutnya dilakukan proses analisis fitur CNN dengan target nya, hasil analisis fitur dapat dilihat pada gambar 3.14. Setelah mendapatkan korelasi fitur tahapan selanjutnya adalah dengan membangun arsitektur SVM model yang telah ditingkatkan.



Gambar 3. 14 Korelasi fitur dengan target



Gambar 3.15 Confussion Matrix

Gambar 3.15 merupakan confussion matrix , didapatkan nilai akurasi 93,17 % dengan nilai precision 93,5%, recall 93,5%, dan f1-score 93,5%. Setelah mendapatkan hasil

tersebut dilanjutkan dengan melakukan optimasi threshold untuk meningkatkan tingkat akurasinya.

```

Optimal threshold: 0.4678

Metrik dengan threshold optimal:
Accuracy: 0.9385
Confusion Matrix:
[[ 9387  281]
 [ 1052 10963]]

```

	precision	recall	f1-score	support
0	0.90	0.97	0.93	9668
1	0.98	0.91	0.94	12015
accuracy			0.94	21683
macro avg	0.94	0.94	0.94	21683
weighted avg	0.94	0.94	0.94	21683

```

Metrik Bisnis:
Total pelanggan dalam test set: 21683
Pelanggan aktual yang churn: 12015 (55.41%)
Pelanggan diprediksi churn (default): 10835 (49.97%)
Pelanggan diprediksi churn (threshold optimal=0.4678): 11244 (51.86%)

10 Pelanggan dengan risiko churn tertinggi:

```

	id	actual_churn	predicted_churn	churn_probability
34853	34853	1	1	1.0
718	718	1	1	1.0
3992	3992	1	1	1.0
23878	23878	1	1	1.0
2346	2346	1	1	1.0
2675	2675	1	1	1.0
17496	17496	1	1	1.0
38357	38357	1	1	1.0
38983	38983	1	1	1.0
19593	19593	1	1	1.0

```

Hasil prediksi telah disimpan ke 'hasil_prediksi_churn_svm.csv'
Model telah disimpan ke 'telecom_churn_svm_model.pkl'

```

Gambar 3.16 Hasil optimasi threshold

Pada gambar 3.16 dapat dilihat hasil akurasi setelah dilakukan optimasi threshold nilai akurasi menjadi 93,85% dengan total data pelanggan yang digunakan untuk test sebesar 21.683 dan didapatkan pelanggan aktual yang churn sebanyak 12.015 pelanggan atau 55,41% dan pelanggan diprediksi churn (treshhold=default) sebanyak 10.835 atau 49.97% setelah dilakukan pengoptimlan threshold dengan nilai threshold optimal 0,4678 didapatkan jumlah pelanggan diprediksi churn sebanyak 11.244 atau 51,86%. Pada gambar 3.16 juga didapatkan 1d 10 pelanggan dengan resiko churn tertinggi. Pada gambar 3.17 dibawah merupakan hasil analisis model SVM, didapatkan akurasi model 93,17% dengan jumlah total pelanggan yang dianalisis berjumlah 72.274 dengan jumlah pelanggan yang terindikasi churn sebesar 55,41% dengan 40.050 pelanggan.


```
📄 Ringkasan Model Prediksi Churn
=====
Jumlah total pelanggan dalam analisis: 72274
Jumlah total pelanggan churn: 40050 (55.41%)
Akurasi model: 93.17%
AUC score: 0.9716

✅ Analisis Selesai!
```

Gambar 3.17 Hasil model prediksi churn dengan CNN

3.2 Hasil

Tabel 3.4 Hasil model prediksi churn

Metode	Akurasi	Total Pelanggan Churn
MLP	98,78%	40.050 (55,41%)
CNN	97,54%	40.050 (55,41%)
SVM	93,17%	40.050 (55,41%)

Tabel 3.4 menunjukkan hasil model prediksi churn menggunakan metode MLP, CNN, SVM. Metode SVM menghasilkan tingkat akurasi model paling rendah yaitu 93,17, dan metode CNN mendapatkan tingkat akurasi 97,54% dan metode MLP mendapatkan tingkat akurasi tertinggi sebesar 98,78%.

BAB IV PENUTUP

4.1 Kesimpulan

Berdasarkan hasil analisis dan pengujian klasifikasi churn pelanggan PT. Internet menggunakan tiga algoritma machine learning, dapat disimpulkan bahwa:

1. Model Multilayer Perceptron (MLP) menunjukkan performa tertinggi dengan akurasi 98,78% dan mencapai 98,98% setelah optimasi threshold. MLP menghasilkan metrik precision, recall, dan f1-score sebesar 99%, yang menunjukkan kapabilitas superior dalam mengidentifikasi pelanggan yang berpotensi churn maupun yang loyal.
2. Model Convolutional Neural Network (CNN) mendemonstrasikan performa yang kompetitif dengan akurasi 97,54% dan meningkat menjadi 97,69% setelah optimasi threshold. Meskipun relatif lebih rendah dibandingkan MLP, CNN tetap menawarkan kemampuan ekstraksi fitur yang robust terutama untuk data pelanggan yang kompleks.
3. Model Support Vector Machine (SVM) menghasilkan akurasi terendah di antara ketiga model yakni 93,17% dan 93,85% setelah optimasi threshold. Walaupun demikian, SVM tetap memberikan performa yang dapat diandalkan dengan kompleksitas komputasi yang lebih rendah dibandingkan model deep learning.
4. Dari ketiga model yang diimplementasikan, ditemukan bahwa proses optimasi threshold berkontribusi signifikan dalam meningkatkan performa klasifikasi, dengan peningkatan akurasi antara 0,2% hingga 0,68%. Hal ini mengindikasikan pentingnya fine-tuning parameter decision threshold untuk menghasilkan model prediksi churn yang optimal.
5. Analisis demografi pelanggan menunjukkan bahwa 55,41% dari total 72.274 pelanggan (setara dengan 40.050 pelanggan) teridentifikasi berpotensi churn, yang menggarisbawahi urgensi strategi retensi pelanggan yang efektif bagi PT. Internet.

Secara keseluruhan, pendekatan deep learning, khususnya MLP, menunjukkan superioritas dalam prediksi churn pelanggan pada dataset yang dianalisis. Hal ini dapat diatribusikan pada kemampuan model untuk mempelajari representasi kompleks dan pola non-linear dalam data pelanggan telekomunikasi.

4.2 Saran

Berdasarkan temuan penelitian ini, beberapa saran dapat diajukan untuk pengembangan sistem dan riset lebih lanjut:

1. Implementasi sistem prediksi churn berbasis MLP perlu diintegrasikan ke dalam sistem Customer Relationship Management (CRM) PT. Internet untuk memungkinkan deteksi dini pelanggan yang berisiko churn dan mengaktifkan strategi retensi yang terukur dan tepat sasaran.
2. Eksplorasi teknik ensemble learning yang menggabungkan kekuatan dari ketiga model (MLP, CNN, dan SVM) dapat diinvestigasi untuk mengatasi kelemahan masing-masing model dan potensial meningkatkan performa prediksi secara keseluruhan.
3. Pengembangan model dengan pendekatan deep learning lanjut seperti Recurrent Neural Networks (RNN) atau Transformer dapat dieksplorasi untuk menganalisis aspek temporal dari perilaku pelanggan yang berpotensi memberikan insight tambahan terhadap pola churn.
4. Implementasi feature importance analysis yang lebih mendalam untuk mengidentifikasi faktor-faktor determinan yang berkontribusi terhadap churn pelanggan, sehingga dapat memberikan rekomendasi strategis yang lebih spesifik kepada manajemen PT. Internet.

BAB V

LAMPIRAN

<https://colab.research.google.com/drive/1B7XMybXaHvoOMNqhGxg71Bp1caHk8slj?usp=sharing>